

机器学习：信息论(Information Theory)与决策树(Decision Tree)

Copyright: Jingmin Wei, Automation – Pattern Recognition and Intelligent System, School of Artificial Intelligence and Automation, Huazhong University of Science and Technology

Copyright: Jingmin Wei, Computer Science - Artificial Intelligence, Department of Computer Science, Viterbi School of Engineering, University of Southern California

机器学习：信息论(Information Theory)与决策树(Decision Tree)

1. 信息论基础
2. 自信息：一个事件所包含的信息量
3. 信息熵(*Information Entropy*)
 - 3.1. 性质
4. 微分熵(连续变量的信息熵, *Differential Entropy*)
 - 4.1. 性质
5. 联合熵(*Joint Entropy*)
6. 交叉熵(*Cross Entropy*)
 - 6.1. 性质与应用
7. 相对熵 *Relative Entropy* (*Kullback – Leibler* 散度)
 - 7.1. 性质(和熵的相互关系)
8. *Jensen – Shannon* 散度
 - 8.1. 性质与应用
9. 互信息(*Mutual Information*)
 - 9.1. 性质(和熵的相互关系)
 - 9.2. 应用：特征选择
10. 条件熵(*Conditional Entropy*)
 - 10.1. 条件微分熵
 - 10.2. 性质与应用(和熵的相互关系)
 - 10.3. 应用：信息增益(*Information Gain*)
11. 决策树概述
12. 决策树特征选择
 - 12.1. 熵和决策时分类原则
 - 12.2. 特征选择算法(决策树训练)
13. 决策树生成
 - 13.1. *ID3*
 - 13.2. *C4.5*
14. 决策树剪枝(预防过拟合)
15. 分类与回归树 - *CART*
 - 15.1. 回归树原理
 - 15.2. 划分空间 R_i 上固定的 c_i 值为多少最好?
 - 15.3. 怎样对于空间划分是最好的?
 - 15.4. 回归树算法流程
16. 决策树优缺点
 - 16.1. 优点

1. 信息论基础

信息论主要研究的是对一个信号能够提供信息的多少进行量化，最初用于研究在一个含有噪声的信道上用离散的字母表来发送消息，指导最优的通信编码等。

关于信息的一个基本想法：一个不太可能的事情竟然发生了，要比一个非常可能的时间的发生能提供更多的信息，也就是说导致那些"异常"事件发生的背后拥有着更多我们更想知道的东西。即概率越小的事情发生时，包含的信息量更大。

2. 自信息：一个时间所包含的信息量

如果一个事件发生的概率小，则其包含的信息量大。表示信息量是个减函数。

事件 x, y 满足相互独立($P(x, y) = P(x)P(y)$)，且 (x, y) 联合的信息量应该是 x, y 信息量之和($I(x, y) = I(x) + I(y)$)。所以对概率取对数，信息量可以定义为：

$$I(x) = -\log P(x)$$

在通信领域中， \log 的底数通常以 2 为底(单位：比特)；在机器学习中， \log 的底数通常以 e 为底(单位：奈特)。因此这里和后面的熵的定义都以 e 为底，即：

$$I(x) = -\ln P(x)$$

3. 信息熵(Information Entropy)

熵用来表示当随机变量取多个不同值时，信息量的总体期望。

信息熵用来对概率分布的随机性程度进行度量，反映了一组数据所包含的信息量大小。

随机变量或各系统的熵越大，随机变量或系统的不确定性就越大，反之就越小。即描述的是有关事件 X 的所有可能结果的自信息期望值。

对于离散型随机变量：

$$H(p) = E_p[-\ln p(x)] = -\sum_{i=1}^n p_i \ln p_i$$

其中 n 代表事件 X 的所有 n 种可能的取值， p_i 代表了事件 X 为 i 时的概率且满足 $\sum_{i=1}^n p(x_i) = 1$ 。

信息熵的定义：熵的作用计算损失用于调整梯度递减的步长，如果本次熵损失比上次上损失大，则说明步长太大了。用于决策树的熵越大，说明特征的划分数据能力越强。

3.1. 性质

当 X 服从均匀分布($x_i = \frac{1}{n}$), 熵有极大值 $\ln n$, 当 X 中某一个变量取值的概率为 1, 其他为 0, 熵有极小值 0, 即 $0 \leq H(p) \leq \ln n$ 。

这是一个带约束的优化问题, 可通过拉格朗日乘子法, 以及黑塞矩阵负定(凹函数)证明。

4. 微分熵(连续变量的信息熵, *Differential Entropy*)

对于连续型随机变量的信息熵可以定义为:

$$H(p) = - \int_{-\infty}^{+\infty} p(x) \ln p(x) dx$$

此时的熵是一个泛函。

4.1. 性质

当随机变量 x 服从正态分布 $N(\mu, \sigma^2)$ 时, 熵有极大值, 即正态分布的熵: $\ln(\sqrt{2\pi}\sigma) + \frac{1}{2}$ 。

这是个带约束的泛函极值问题, 可通过拉格朗日乘子法和欧拉-拉格朗日方程证明:

$$F[y] = \int_a^b L(x, y(x), y'(x)) dx$$
$$\text{极值点满足: } \frac{\partial L}{\partial y} - \frac{d}{dx} \left(\frac{\partial L}{\partial y'} \right) = 0$$

5. 联合熵(*Joint Entropy*)

联合熵用来度量二维 / 多维随机变量的不确定性。

对于随机变量 (X, Y) , 其联合分布为 $P(x_i, y_j)$, 则联合熵为:

$$H(X, Y) = - \sum_i \sum_j P(x_i, y_j) \ln P(x_i, y_j)$$

性质: 联合熵是非负的; 如果二者相互独立, 则满足 $H(X, Y) = H(X) + H(Y)$ 。

推广到多维:

$$H(X_1, \dots, X_n) = - \sum_{x_1} \dots \sum_{x_n} P(x_1, \dots, x_n) \ln P(x_1, \dots, x_n)$$

对于连续型随机变量:

$$H(X, Y) = - \int_{-\infty}^{+\infty} \int_{-\infty}^{+\infty} p(x, y) \ln p(x, y) dx dy$$
$$H(x) = - \int_{-\mathbb{R}^n} p(x) \ln p(x) dx$$

多维正态分布 $N(\mu, \Sigma)$ 的联合熵为: $\frac{n}{2} \ln 2\pi + \frac{1}{2}(|\Sigma|) + \frac{n}{2}$, 这个式子表明其只与协方差有关。

6. 交叉熵(Cross Entropy)

交叉熵的定义和熵是类似的，但是定义在两个概率分布上，主要用于衡量两个分布的相似度。

对于离散型概率分布 $p(x), q(x)$ ，定义交叉熵为：

$$H(p, q) = E_p[-\ln Q(X)] = - \sum_x P(X) \ln Q(X)$$

其值越大，两个概率分布的差异也就越大，反之越小。[Lesson 3.5 参数估计\(MLE, MAP, Bayes, KNN, Parzen, GMM, EM算法\)](#)我们学习到，如果 LR (逻辑回归)和 $Softmax$ 从最大似然的角度解释，即当给出了标签和训练集 (y_{label}, X) ，求使得 $p(y|X, \theta)$ 最大的参数 θ 。表示既然这组样本出现了，那么它们出现的概率理应是最大化的。如果 LR 和 $Softmax$ 从交叉熵的角度解释，就是最小化 y_{pred} 和 y_{label} 之间的分布差异。最大似然和最小化交叉熵，其实在 LR 算法中，是一个意思。

对于连续型随机变量：

$$H(p, q) = E_p[-\ln Q(x)] = - \int_{-\infty}^{+\infty} p(x) \ln q(x) dx$$

如果两个概率分布相同，则交叉熵退化为熵，即 $H(p, q) = H(p) = H(q)$ 。

6.1. 性质与应用

交叉熵不具有对称性，不是距离度量，也不满足三角不等式。

当两个的概率分布相等时，交叉熵有极小值。可通过拉格朗日乘子和黑塞矩阵正定(凸函数)来证明。

题外话： $Logistic, Softmax$ 回归的目标函数，就是求这个损失的极小值，即让 y_{pred}, y_{label} 之间的差异尽可能小。

交叉熵被应用于 $Logistic$ 回归和 $Softmax$ 回归问题([Lesson 5 监督学习之分类\(Logistic, Bayes, MAP\)](#))。

7. 相对熵 Relative Entropy (Kullback – Leibler 散度)

相对熵的定义由熵和交叉熵共同决定，它和交叉熵类似，主要也用来衡量两个分布的相似度。

相对熵又称为 KL 散度，信息散度，信息增益，常用在对抗神经网络里。

在很多算法中，假设连续随机变量 x ，其概率分布为 $p(x)$ ，模型得到的近似分布为 $q(x)$ 。二者的相对熵越大，两个概率分布的差异也就越大。我们的目标就是最小化这个相对熵。

对于离散型概率分布 p, q ，其 KL 散度为：

$$\begin{aligned} D_{KL}(p||q) &= - \sum_{i=1}^n p(x_i) \log q(x_i) - \left(- \sum_{i=1}^n p(x_i) \log p(x_i) \right) \\ &= \sum_{i=1}^n p(x_i) \log \frac{p(x_i)}{q(x_i)} \end{aligned}$$

两个伯努利分布的 $D_{KL}(p||q) = p_1 \ln \frac{p_1}{p_2} + (1 - p_1) \ln \frac{1-p_1}{1-p_2}$ 。

对于连续型概率分布 p, q , 其 KL 散度为:

$$D_{KL}(p||q) = - \int_{-\infty}^{+\infty} p(x) \ln \frac{p(x)}{q(x)} dx$$

两个正态分布的 $D_{KL}(p||q) = \ln \frac{\sigma_1}{\sigma_2} \int_{-\infty}^{+\infty} p_1(x) dx + \int_{-\infty}^{+\infty} \frac{(x-\mu_2)^2}{2\sigma_2^2} p_1(x) dx - \int_{-\infty}^{+\infty} \frac{(x-\mu_1)^2}{2\sigma_1^2} p_1(x) dx$ 。

根据正态分布方差和数学期望计算公式, 可以简化为: $D_{KL}(p||q) = \frac{1}{2} (\ln \frac{\sigma_2^2}{\sigma_1^2} + \frac{\sigma_1^2}{\sigma_2^2} + \frac{\mu_1 - \mu_2}{\sigma_2^2} - 1)$ 。

如果第一个正态分布各变量独立(协方差矩阵为对角阵), 第二个正态分布是标准正态 $N(0, I)$, 则二者的 KL 散度为: $\frac{1}{2} \sum_{i=1}^d (\sigma_i^2 + \mu_i^2 - \ln \sigma_i^2 - 1)$ 。

对于多维正态分布的 $D_{KL}(p||q) = \frac{1}{2} (\ln \frac{|\Sigma_2|}{|\Sigma_1|} - d + \text{tr}(\Sigma_2^{-1} \Sigma_1) + (\mu_2 - \mu_1)^T \Sigma_2^{-1} (\mu_2 - \mu_1))$ 。

7.1. 性质(和熵的相互关系)

满足 *Gibbs* 不等式, 即 $D_{KL}(p||q) \geq 0$, 当且仅当 $p(x) = q(x)$, KL 散度取最小值 0 。

KL 散度不具有对称性, 不是距离度量, 也不满足三角不等式。

KL 散度和交叉熵一样, 也反映了两个概率分布之间的差异程度。其定义公式可推导为交叉熵和熵的差:

$$D_{KL}(p||q) = H(p, q) - H(p)$$

如果某机器学习算法需要以 $p(x)$ 为目标, 以 $q(x)$ 作为拟合函数, 此时 $H(p)$ 是不变的, 只需要计算 $H(p, q)$ 即可, 这也从 KL 散度角度说明了逻辑回归(交叉熵)本身的正确性。

8. Jensen – Shannon 散度

JS 散度根据 KL 散度来构造, 也用来衡量两个分布的相似度。不同的是, 它具有对称性。

$$D_{JS}(p||q) = \frac{1}{2} D_{KL}(p||m) + \frac{1}{2} D_{KL}(q||m)$$

其中概率分布 m 为 p, q 的平均值:

$$m(x) = \frac{1}{2} (p(x) + q(x))$$

8.1. 性质与应用

JS 散度其实是根据 KL 散度的均值构造, $D_{JS}(q||p) \geq 0$, 且具有对称性:

$$D_{JS}(q||p) = D_{JS}(p||q)$$

当且仅当 $m(x) = p(x) = q(x)$ 时, 有最小值 $D_{JS}(p||q) = 0$ 。和 KL 散度一样, JS 散度越大, 两个概率分布之间的差异也就越大。

应用: KL, JS 散度常被用于流型学习([Lesson 8 无监督学习\(聚类, 信号分解, 流形降维\)](#)), 变分推断([Lesson 3.5 参数估计\(MLE, MAP, Bayes, KNN, Parzen, GMM, EM算法\)](#)), 以及生成对抗网络。

9. 互信息(Mutual Information)

互信息用来衡量两个相同的一维分布变量之间的独立性，或者说相关性和依赖程度。

$I(X, Y)$ 是衡量联合分布 $p(x, y)$ 和 $p(x)p(y)$ 分布之间的关系，即他们之间的相关系数。两个随机变量的依赖程度越高，则互信息值越大，反之越小。

设两个随机变量 (X, Y) 的联合分布为 $p(x, y)$ ，边际分布分别为 $p(x), p(y)$ ，则互信息定义为：

$$\begin{aligned} I(X, Y) &= \sum_{x \in X} \sum_{y \in Y} p(x, y) \ln \frac{p(x, y)}{p(x)p(y)} \\ &= D_{KL}(p(x, y) || p(x)p(y)) \end{aligned}$$

9.1. 性质(和熵的相互关系)

$I(X, Y) \geq 0$ ，当且仅当两个事件独立时，取最小值 0；如果两个变量之间相互独立 $p(x, y) = p(x)p(y)$ ，则 $I(X, Y) = 0$ 。

相互关系和结果推导：

$$\begin{aligned} I(X, Y) &= H(X) - H(X|Y) \\ &= H(X) + H(Y) - H(X, Y) \\ &= \sum_x p(x) \ln \frac{1}{p(x)} + \sum_y p(y) \ln \frac{1}{p(y)} - \sum_{x,y} p(x, y) \ln \frac{1}{p(x, y)} \\ &= \sum_{x,y} p(x, y) \ln \frac{p(x, y)}{p(x)p(y)} \end{aligned}$$

即两个变量的联合熵等于它们各自的熵之和减去互信息：

$$H(X, Y) = H(X) + H(Y) - I(X, Y)$$

这一结论类比于两个集合的并集。根据互信息定义，也可以推导出 $I(X, Y) \leq H(X)$ ， $I(X, Y) \leq H(Y)$ 。

当两个变量相互独立时，有：

$$H(X, Y) = H(X) + H(Y)$$

9.2. 应用：特征选择

互信息常用语特征选择，如果 Y 为标签， X 为数据，则二者的互信息反映了类别和标签的相关程度。在做分类前，可以先进行特征选择，选取一部分互信息最大的特征列，排除其他列，最终形成最后用于训练的特征向量。

特征选择的合理使用，可以极大地提高模型的泛化能力。

10. 条件熵(Conditional Entropy)

条件熵用于衡量，已知一个随机变量的取值条件下，另一个随机变量的信息量。

或者表示为 X 给定条件下， Y 的条件概率分布的熵对 X 的数学期望(平均不确定性)。

对于随机变量 Y ，在 X 的条件下其条件熵为：

$$\begin{aligned} H(Y|X) &= \sum_{i=1}^n P(X = x_i) H(Y|X = x_i) \\ &= - \sum_i \sum_j P(x_i, y_j) \ln P(y_j|x_i) \\ &= - \sum_i \sum_j P(x_i, y_j) \ln \frac{P(x_i, y_j)}{P(x_i)} \end{aligned}$$

相比于联合熵，条件熵只多了分母一项。

10.1. 条件微分熵

即连续变量的条件熵：

$$H(Y|X) = - \int_{-\infty}^{+\infty} \int_{-\infty}^{+\infty} p(x, y) \ln \frac{p(x, y)}{p(x)} dx dy$$

10.2. 性质与应用(和熵的相互关系)

$H(Y|X) \geq 0$ ，当且仅当 Y 完全由 X 确定时，值为 0。

当且仅当这两个随机变量相互独立时， $H(Y|X) = H(Y)$ 。

相互关系和结果推导：

$$\begin{aligned} H(X, Y) &= H(X) + H(Y|X) = H(Y) + H(X|Y) \\ H(X, Y) &= - \sum_i \sum_j P(x_i, y_j) \ln P(x_i, y_j) \\ &= - \sum_i \sum_j P(x_i, y_j) \ln P(y_j|x_i) + (- \sum_i (\sum_j P(x_i, y_j)) \ln P(x_i)) \\ &= H(Y|X) + H(X) \end{aligned}$$

即：

$$H(Y|X) = H(X, Y) - H(X)$$

X 对 Y 的条件熵是它们的联合熵和 $H(X)$ 的差值。可推导 $H(X, Y) \geq \max(H(X), H(Y))$ 。

又 $\because H(X, Y) = H(X) + H(Y) - I(X, Y)$ ，可以得到：

$$I(X, Y) = H(X) - H(X|Y)$$

即互信息等于熵和条件熵的差。并且能推导 $H(X) \geq H(X|Y)$ 。

10.3. 应用：信息增益(Information Gain)

假设系统原有的熵为 $H(Y)$ ，后来引入了特征 T ，在固定特征 T 的情况下，系统的混乱度减小，熵减小为 $H(Y|T)$ ，那么特征 T 给系统带来的信息增益为：

$$IG(T) = H(Y) - H(Y|T)$$

其意义可以看成，决策树左右子集划分后，信息熵的下降值。信息增益为决策树算法的构造基础。

11. 决策树概述

决策树从父节点往子节点挨个分类。

决策树在分类问题中，表示基于特征对实例空间进行划分的方法，可以视为 *if - then* 规则的集合，也可以认为是定义在特征空间和类空间上的条件概率分布。

步骤：

- 特征选择
- 决策树生成
- 决策树剪枝(防止过拟合)

12. 决策树特征选择

作用：决定选取哪些特征来划分特征空间。

在进一步讨论特征选择之前，首先需要根据之前信息论的知识，定义一个概念：信息增益。

$$\begin{aligned}\text{信息增益} &= \text{信息熵} - \text{条件熵} \\ &= H(D) - H(D|A)\end{aligned}$$

信息熵表示随机变量的不确定性。

条件熵表示给定一个特征属性的情况下，随机变量的不确定性。

随机事件： P 。

信息量： $\log \frac{1}{P} = -\log P$ 。

12.1. 熵和决策时分类原则

信息量对于 $P(X)$ 的期望。熵用来对概率分布的随机性程度进行度量，反映了一组数据所包含的信息量大小。

在决策树的生成中，各类样本出现的概率服从一个概率分布，如果熵越小，说明内部的样本越纯(即树的子集都为其中的某一类或者某几类样本)。换句话说，在信息熵中我们知道，当所有的样本都只属于某一类时，熵有极小值；当样本均匀地分布在所有类别中，熵有极大值。

这也是 *ID3* 决策树的分类规则。

$$H(X) = E_{P(X)}[\log P]$$

复习信息论的内容：

设 X 是一个有限的离散随机变量，其概率分布如下：

$$P(X = x_i) = p_i, \quad i = 1, 2, \dots, n$$

熵的离散型：

$$H(x) = - \sum_x P(x) \ln(x)$$

$$D = \{(x_i, y_i)\}_{i=1}^m$$

$$H(D)$$

用积分来表示连续型：

$$\int -P(x) \ln(P(x)) dx$$

交叉熵：当随机变量只取两个值，例如 1, 0 时：

$$P(X = 1) = p$$

$$P(X = 0) = 1 - p$$

$$\text{熵} : H(X) = -p \ln p - (1 - p) \ln(1 - p)$$

条件熵：设有随机变量 (X, Y) ，其联合概率分布为：

$$P(X = x_i, Y = y_j) = p_{ij}, \quad i = 1, 2, \dots, n; j = 1, 2, \dots, m$$

定义条件熵 $H(Y|X)$ ，其表示为 X 已知的情况下 Y 的不确定性：

$$H(Y|X) = \sum_{i=1}^n P(X = x_i) H(y|X = x_i)$$

$$H(y|X = x_i) \text{表示在 } X = x_i \text{ 的情况下 } Y \text{ 的条件熵}$$

定义信息增益：特征 A 对训练数据集 D 的信息增益定义为：(其表示为在 A 已知的情况下 D 的不确定性的减少量)

$$g(D|A) = H(D) - H(D|A)$$

12.2. 特征选择算法(决策树训练)

利用信息增益进行特征选择：选取信息增益最大的特征来作为决策树的父节点，也就是说，有无该特征对数据集的影响最大。

$$\arg \max_{A_i} g(D|A_i) = H(D) - H(D|A_i)$$

训练数据集 $|D|$ 表示样本容量，设有 K 个类 $C_k, k = 1, \dots, K$ ，特征 A_i 设有 n_i 个不同取值(其为离散的特征变量)，则根据 A_i 的不同将 D 划分为 n_i 个子集，并记 $|D_{ik}| = |D_i \cap C_k|$ 。

特征的信息增益算法流程如下：

1. 计算数据集 D 的熵 $H(D)$ ：

$$H(D) = - \sum_{k=1}^K \frac{|C_k|}{|D|} \log \frac{|C_k|}{|D|}$$

2. 计算特征 A_i 对于数据集 D 的条件熵 $H(D|A_i)$:

$$H(D|A_i) = \sum_{i=1}^{n_i} \frac{|D_i|}{|D|} H(D_i) = - \sum_{i=1}^{n_i} \frac{|D_i|}{|D|} \sum_{k=1}^K \frac{|D_{ik}|}{|D_i|} \log \frac{|D_{ik}|}{|D_i|}$$

3. 计算 A_i 的信息增益:

$$g(D|A_i) = H(D) - H(D|A_i)$$

即根据 1, 2 两个公式, 计算信息增益, 并选择信息增益最大的特征。

$$\arg \max_{A_i} g(D|A_i) = H(D) - H(D|A_i)$$

13. 决策树生成

基于前文的特征选择算法, 可以构造两种经典树: $ID3$, $C4.5$ 。

13.1. $ID3$

主要思想是: 对于每个分裂规则, 用 $ID3$ 分为左右子集 D_L, D_R , 并计算熵 $H(D_L), H(D_R)$ 。如果能找到一个判定规则, 让二者的熵最小化, 则它就能使分裂后的左右子集的纯度最大化。

这个判定规则就是前文所说的信息增益:

$$g(D|A_i) = H(D) - H(D|A_i)$$

信息增益的意义可以看成, 决策树左右划分后熵的下降值。信息增益越大, 表明熵下降的最多, 也就表明划分之后的子集更纯。因此 $ID3$ 主要就是根据熵计算信息增益, 并极大化这个增益。

基于信息增益特征选择的 $ID3$ 流程如下:

- 从根节点的全量数据开始, 计算各特征的的信息增益。
- 选取特征信息增益最大的构建分支, 以特征类型将数据分割为各子数据集, 并去除其使用的特征。
- 在分割的子数据集和子节点上, 重复调用前两步, 直到信息增益小于给定阈值或者数据无特征为止, 将其标签的众数作为类标签。

13.2. $C4.5$

$C4.5$ 算法即为将 $ID3$ 中的特征选择方式由信息增益替换为信息增益比。

特征的信息增益比算法:

1. 计算数据集 D 关于 A_i 的熵 $H_{A_i}(D)$:

$$H_{A_i}(D) = - \sum_{i=1}^{n_i} \frac{|D_i|}{|D|} \log \frac{|D_i|}{|D|}$$

2. 计算 A_i 的信息增益比(规避离散化太强的特征作为主结点的可能)：

$$g_R(D|A_i) = \frac{g(D|A_i)}{H_{A_i}(D)} = \frac{\text{信息增益}}{\text{切分信息}}$$

14. 决策树剪枝(预防过拟合)

树的规模越大，在模型训练中的拟合效果虽然会更好，但模型的泛化能力会下降。

实现方式：极小化决策树整体的损失函数或者代价函数。

函数定义：设树 T 的叶子节点数为 $|T|$ ， t 是数 T 的叶子节点，记该叶子节点有 N_t 个样本点，其中 k 类的样本点有 N_{tk} 个，则定义损失函数为：

$$C_\alpha(T) = \sum_{i=1}^{|T|} N_t H_t(T) + \alpha |T|, \text{ 其中 } H_t(T) = - \sum_k \frac{N_{tk}}{N_t} \log \frac{N_{tk}}{N_t}$$

$\alpha |T|$ 类似于回归的惩罚项

剪枝流程：

1. 递归的从树的叶子节点回溯。
2. 计算并比较其损失函数，若 $C_\alpha(T)$ 在剪枝后更小则剪枝。
3. 返回第一步，直到根节点。

15. 分类与回归树 - CART

CART 的假设条件：假设决策树是二叉树形式(即一次的特征只能将数据集分为两个类别)

相对于 ID3、C4.5，CART 可以对于连续型变量进行分类和回归，但每个特征只能对数据集进行二分类。

15.1. 回归树原理

$$D = (x_1, y_1), (x_2, y_2), \dots, (x_N, y_N)$$

$$\text{其中例如：} x_1 = (x_1^{(1)}, x_1^{(2)}, \dots, x_1^{(N)})$$

假设已经将输入空间划分为 M 个单元 R_1, R_2, \dots, R_M ，并在 R_i 上固定一个输出值 c_i ：

$$f(x) = \sum_{m=1}^M c_m I(x \in R_m)$$

对于回归树，误差函数可以形象化定义为：

$$\sum_{x_i \in R_m} (y_i - f(x_i))^2$$

由此产生的几个问题：

- 怎样对于空间划分是最好的？
- 划分空间 R_i 上固定的 c_i 值为多少最好？

15.2. 划分空间 R_i 上固定的 c_i 值为多少最好?

由误差函数可知:

$$\hat{c}_m = \text{average}(y_i | x_i \in R_m)$$

时是最佳的。(类似于总长一定, 正方形面积最小, 而这个问题可以用概率期望解释)

15.3. 怎样对于空间划分是最好的?

在思考这个问题之前要思考另一个问题: 假设我们用第 j 个特征进行切分, 我们怎样选取切分点(明确特征为连续型特征, eg: 用一条鱼的长度分大鱼和小鱼), 不可用特征对于结果进行直接划分。对此我们需要找到一个切分点构建一个映射关系。(对于上例来说就是找到一个标准长度, 大于这个长度将其视为大鱼, 小于等于这个长度将其视为小鱼)

概念化说明:

假设选择第 j 个变量 $x^{(j)}$ 作为切分变量, s 是其切分点, 则输入空间可以划分为:

$$R_1(j, s) = \{x | x^{(j)} \leq s\} \quad \text{和} \quad R_2(j, s) = \{x | x^{(j)} > s\}$$

而目标函数可定义为:

$$\min_{j,s} \left[\min_{c_1} \sum_{x_i \in R_1(j,s)} (y_i - c_1)^2 + \min_{c_2} \sum_{x_i \in R_2(j,s)} (y_i - c_2)^2 \right]$$

对于固定的 j :

$$\hat{c}_1 = \text{ave}\{y_i | x_i \in R_1(j, s)\} \quad \text{和} \quad \hat{c}_2 = \text{ave}\{y_i | x_i \in R_2(j, s)\}$$

遍历所有的输入变量, 找到最优的切分变量 j 。

15.4. 回归树算法流程

1. 求解:

$$\min_{j,s} \left[\min_{c_1} \sum_{x_i \in R_1(j,s)} (y_i - c_1)^2 + \min_{c_2} \sum_{x_i \in R_2(j,s)} (y_i - c_2)^2 \right]$$

2. 对于选定的 (j, s) 划分区域和决定其输出:

$$R_1(j, s) = \{x | x^{(j)} \leq s\} \quad \text{和} \quad R_2(j, s) = \{x | x^{(j)} > s\}$$
$$\hat{c}_m = \frac{1}{N_m} \sum_{x_i \in R_m(j,s)} y_i$$

3. 对于划分的子区域重返第一步。

求解出生成的回归决策树:

$$f(x) = \sum_{m=1}^M c_m I(x \in R_m)$$

16. 决策树优缺点

16.1. 优点

- 不需要任何领域知识或者参数假设。
- 适合高维数据。
- 简单易于理解。
- 短时间内处理大量数据，得到可行且效果较好的结果

16.2. 缺点

- 对于各类别样本数量不一致的数据，信息增益偏向于那些具有更多数值的特征。
- 易于过拟合，特别是特征多的情况下，容易引入噪声特征。
- 忽略属性之间的相关性。
- 不支持在线学习。